

ChromaTruth: Detecção de Deepfakes através de Inconsistências na Reconstrução Cromática

João Craveiro
Universidade da Beira Interior
Redes Neurais e Deep Learning (2025/2026)
55108

Resumo

A detecção de deepfakes baseada em classificadores binários tem mostrado fragilidades com a evolução de métodos generativos modernos, em particular modelos de difusão e técnicas avançadas de *inpainting*. Este trabalho propõe uma abordagem alternativa: em vez de aprender diretamente “padrões de falso”, treina-se um modelo de *colorization* sobre faces reais para capturar coerência cromática natural. Em seguida, imagens suspeitas são convertidas para tons de cinzento e recolorizadas pelo modelo; discrepâncias entre a imagem original e a reconstruída são agregadas em mapas de erro (*heatmaps*) e em *scores* globais. Avaliamos a capacidade de separação Real vs. Fake com a métrica AUC-ROC, explorando múltiplas funções de *score*, percentis e configurações experimentais, incluindo testes que falharam (ex.: uso de máscaras faciais) e ajustes que melhoraram substancialmente o desempenho. A melhor configuração atingiu $AUC \approx 0.7627$, com elevada precisão no limiar selecionado e recall competitivo, suportada por análise qualitativa dos *heatmaps*.

Palavras-chave: deepfakes, inpainting, modelos de difusão, colorization, espaço Lab, heatmaps, AUC-ROC.

1 Contexto e Motivação

A detecção automática de deepfakes tornou-se mais desafiante com a transição de técnicas clássicas (ex.: GANs) para métodos modernos baseados em modelos de difusão e pipelines de edição guiada. Em particular, o *inpainting* permite substituir regiões específicas da face mantendo alta fidelidade visual, o que reduz a eficácia de detectores tradicionais que dependem de “impressões digitais” (*fingerprints*) específicas de arquiteturas ou artefactos recorrentes.

Este projeto segue a hipótese proposta no enunciado: uma face real apresenta coerência física intrínseca entre luminância (estrutura) e cromaticidade (cor). Manipulações como *face swaps* e *inpainting* podem quebrar subtilmente essa coerência. A ideia central é aprender o que está “certo” numa imagem real (em vez de aprender apenas padrões de falso) e medir desvios cromáticos quando o modelo tenta reconstruir a cor de uma imagem potencialmente manipulada.

Para isso, construímos um pipeline completo que: (i) parte de um conjunto grande de faces reais (FFHQ), (ii) gera imagens falsas realistas por *inpainting*, (iii) treina

um modelo de *colorization* apenas com imagens reais, (iv) calcula mapas de erro de reconstrução, (v) agrega esses mapas em *scores* e avalia com AUC-ROC.

2 Objetivos do Projeto

Os objetivos do trabalho foram:

- **Gerar um dataset adversarial realista:** construir pares (I_{real}, I_{fake}) a partir de imagens reais do FFHQ, criando manipulações por *inpainting* que preservem o aspeto fotográfico.
- **Treinar um “detetive cromático”:** desenvolver e treinar um modelo de Deep Learning para *colorization* (reconstrução de cromaticidade) usando apenas imagens reais, com pré-processamento adequado no espaço de cor Lab.
- **Detetar via inconsistência:** aplicar o modelo a imagens reais e falsas, gerar *heatmaps* de erro, e definir *scores* capazes de separar as classes.
- **Avaliar rigorosamente:** medir desempenho com AUC-ROC e avaliar a escolha de limiares com métricas (Accuracy, Precision, Recall, F1/F2), garantindo que pares real/fake permanecem consistentes nos *splits*.
- **Analisar sucessos e falhas:** reportar testes que melhoraram (ex.: ajuste de percentis e *score* final) e testes que degradaram (ex.: máscaras faciais), justificando tecnicamente as conclusões.

O dataset total de faces reais utilizado continha 52 001 imagens, divididas com seed fixa (42) em treino (41 600) e teste (10 401), garantindo reprodutibilidade dos resultados.

3 Metodologia

Nesta secção descrevemos detalhadamente o pipeline proposto, desde a preparação dos dados até à obtenção dos mapas de erro cromático utilizados para detecção. A abordagem segue uma estratégia *self-supervised*, treinando um modelo exclusivamente com imagens reais e avaliando inconsistências quando aplicado a imagens manipuladas.

3.1 Dataset e Divisão dos Dados

Foi utilizado o dataset **FFHQ (Flickr-Faces-HQ)**, constituído por imagens faciais de alta qualidade e grande diversidade demográfica. A partir do conjunto original, foram consideradas 52 001 imagens reais.

Para garantir reprodutibilidade e evitar fuga de informação, os dados foram divididos com uma *seed* fixa (42), resultando em:

- 41 600 imagens para treino (80%)
- 10 401 imagens para teste (20%)

Esta divisão foi mantida fixa ao longo de todas as experiências, assegurando que cada imagem real e a sua correspondente versão falsa pertencem sempre ao mesmo subconjunto (treino ou teste).

3.2 Geração de Deepfakes por Inpainting

Para a criação de exemplos falsos, foi adotada uma abordagem baseada em *inpainting* facial utilizando **Stable Diffusion**. Este método permite modificar regiões específicas da face preservando coerência global e realismo visual, simulando ataques modernos difíceis de detetar.

O processo consistiu em:

1. Detecção da face e definição de uma região de interesse.
2. Aplicação de *inpainting* para alterar zonas faciais mantendo iluminação e textura compatíveis.
3. Geração de pares (I_{real}, I_{fake}) para cada imagem selecionada.

Foram testadas diferentes quantidades de imagens falsas (3 000, 6 000 e 12 000), permitindo estudar o impacto do volume de dados adversariais no desempenho final do sistema.

3.3 Modelo de Colorization

O núcleo do sistema é um modelo de Deep Learning treinado para *image colorization*. O modelo recebe como entrada imagens em tons de cinzento e aprende a reconstruir os canais de crominância, sendo treinado exclusivamente com imagens reais.

Pré-processamento. As imagens RGB foram convertidas para o espaço de cor **Lab**, separando explicitamente:

- Canal *L*: luminância (estrutura)
- Canais *a* e *b*: crominância (cor)

Durante o treino, apenas o canal *L* é fornecido ao modelo como entrada, enquanto os canais (a, b) são usados como alvo.

Treino. O modelo foi treinado com:

- Otimizador Adam
- Treino em GPU (CUDA)
- *Early stopping* baseado na *validation loss*

Ao longo do treino, o modelo atingiu valores estáveis de *loss* e *accuracy*, sendo guardado automaticamente o melhor modelo de acordo com o erro de validação.

3.4 Mapas de Erro Cromático

Após o treino, o modelo é aplicado a imagens reais e falsas. Para cada imagem:

1. A imagem original é convertida para tons de cinzento.
2. O modelo reconstrói os canais de cor.
3. Calcula-se o erro absoluto entre a crominância original e a reconstruída.

O resultado é um **mapa de erro cromático** (*heatmap*), onde valores elevados indicam regiões onde a reconstrução falhou, sugerindo inconsistência entre estrutura e cor.

Estes mapas não são usados para segmentação explícita, mas sim como base para a extração de *scores* globais, descritos na secção seguinte.

4 Detecção e Avaliação Experimental

Esta secção descreve a forma como os mapas de erro cromático são agregados em métricas discriminativas e apresenta os principais testes experimentais realizados, incluindo decisões metodológicas, falhas identificadas e melhorias progressivas do sistema.

4.1 Extração de Scores a partir dos Heatmaps

Os mapas de erro cromático gerados pelo modelo de *colorization* apresentam uma distribuição espacial contínua, sem fronteiras claras entre regiões reais e manipuladas. Assim, em vez de procurar localizar explicitamente a edição, optou-se por agregar o erro em *scores* globais.

Foram testadas várias funções de agregação, entre as quais:

- **Percentil elevado do erro** (*score_p99*): valor correspondente ao percentil 99 do mapa.
- **Média dos maiores picos** (*top1 mean*): média dos valores mais elevados do heatmap.
- **Score composto**: combinação linear de diferentes estatísticas do erro.
- **Rácio de erro**: comparação entre estatísticas de erro da imagem reconstruída e da imagem original.

Estes *scores* foram avaliados individualmente com a métrica AUC-ROC, permitindo identificar quais apresentavam maior capacidade discriminativa.

4.2 Comparação de Múltiplos Scores

Durante o desenvolvimento do sistema foram avaliadas várias estratégias de agregação do erro cromático, com o objetivo de maximizar a separação entre imagens reais e manipuladas.

Entre os métodos testados destacam-se:

- **score_p99 / score_99**: baseado diretamente no percentil 99 do mapa de erro cromático.
- **score_peak_ratio**: rácio entre picos de erro da imagem reconstruída e estatísticas de referência.
- **fused_score**: combinação de múltiplos scores numa única métrica agregada.

Embora alguns destes métodos tenham apresentado desempenho razoável, observou-se que:

- O *score_p99* é excessivamente sensível a picos isolados de erro, resultando em instabilidade e variação elevada da AUC.
- O *score_peak_ratio* mostrou-se dependente de valores extremos, degradando a separação em cenários com erro cromático mais distribuído.
- O *fused_score*, apesar de conceptualmente atrativo, introduziu ruído adicional e reduziu a interpretabilidade do sistema, sem ganhos consistentes de desempenho.

Com base nestes resultados, optou-se por abandonar estas abordagens intermédias e adotar um *score* mais simples e robusto, conduzindo à definição do *score_mix* utilizado na configuração final.

4.3 Sweep de Percentis e Escolha de PHIGH

Um aspeto crítico do método é a escolha do percentil elevado utilizado na agregação do erro. Foram testados vários valores de *PHIGH*, variando entre 70 e 99.9.

Os resultados mostraram que:

- Percentis demasiado elevados (ex.: 99.9) capturam apenas picos extremos, resultando em menor separação.
- Percentis intermédios (aproximadamente entre 82 e 85) maximizam a AUC.

Este comportamento indica que o sinal discriminativo está distribuído globalmente pelo rosto e não concentrado em artefactos pontuais. Assim, foi selecionado **PHIGH = 85** como compromisso ótimo entre sensibilidade e robustez.

4.4 Testes com Máscaras Faciais

Foi avaliada a hipótese de restringir a análise exclusivamente à região facial através de máscaras. Embora intuitiva, esta abordagem resultou numa degradação consistente do desempenho.

A análise qualitativa revelou que:

- Parte do erro cromático relevante ocorre fora da face (ex.: cabelo, contornos, fundo próximo).
- O uso de máscaras elimina informação contextual útil para a deteção.

Como consequência, as máscaras faciais foram abandonadas na configuração final.

4.5 Impacto do Número de Imagens Falsas

Foram testadas diferentes quantidades de imagens falsas geradas por *inpainting*:

- 3 000 imagens
- 6 000 imagens
- 12 000 imagens

Observou-se que o aumento inicial do número de fakes melhora significativamente a AUC. No entanto, passar de 6 000 para 12 000 imagens não resultou em ganhos adicionais, tendo inclusive provocado ligeira degradação em algumas métricas.

Com base nestes resultados, foi adotado o conjunto de **6 000 imagens falsas** na configuração final.

4.6 Score Final e Avaliação ROC

Após a comparação sistemática dos diferentes *scores*, foi definida uma métrica final (*score_mix*), que combina estatísticas de erro global com um peso $\lambda = 0.9$.

A avaliação foi realizada através de:

- Curva ROC
- AUC-ROC como métrica principal
- Seleção de *threshold* no conjunto de calibração

A melhor configuração atingiu uma **AUC de aproximadamente 0.7627**, demonstrando capacidade consistente de separação entre imagens reais e manipuladas, mesmo perante manipulações visuais altamente realistas.

A análise do *threshold* revelou elevada precisão, com *recall* competitivo, validando a robustez prática do método proposto.

4.7 Separação entre Avaliação Discriminativa e Decisão Binária

Durante o desenvolvimento do sistema, a avaliação foi deliberadamente dividida em duas etapas complementares, implementadas em scripts distintos: *test_auc_coluna.py* e *evaluate_threshold.py*.

O script *test_auc_coluna.py* é responsável por medir exclusivamente a capacidade discriminativa dos diferentes *scores*, recorrendo à métrica AUC-ROC. Esta avaliação é independente de qualquer limiar de decisão e permite comparar objetivamente diferentes funções de agregação do erro cromático, focando-se apenas na separação estatística entre imagens reais e manipuladas.




Figura 1: Curva ROC obtida com o score final (PHIGH=85), evidenciando $AUC \approx 0.7627$.

Por outro lado, o script `evaluate_threshold.py` avalia o comportamento prático do sistema quando utilizado como detetor binário. Nesta fase, um *threshold* é calibrado num conjunto dedicado e aplicado ao conjunto de avaliação, permitindo medir métricas dependentes da decisão, como Accuracy, Precision, Recall, F1 e F2. Esta separação garante que a escolha do limiar não influencia artificialmente a avaliação da capacidade discriminativa do modelo.

Esta estratégia permite uma análise mais rigorosa e alinhada com boas práticas experimentais, distinguindo claramente a qualidade intrínseca do *score* da sua utilização num cenário real de deteção.

4.8 Forma da Curva ROC

A AUC-ROC foi adotada como métrica principal por ser independente do *threshold* e mais robusta a diferentes distribuições de classes.

A curva ROC obtida apresenta uma forma escalonada, com degraus pronunciados em vez de uma transição suave. Este comportamento não corresponde a um erro de implementação, mas resulta diretamente da natureza do *score* utilizado.

Em particular, o *score_mix* baseia-se em estatísticas agregadas do mapa de erro cromático, como percentis elevados e médias de picos, produzindo um conjunto limitado de valores distintos. Como consequência, o número de *thresholds* únicos é reduzido, originando uma curva ROC menos contínua.

Adicionalmente, o método opera ao nível da imagem, produzindo um único *score* global por amostra, em contraste com classificadores probabilísticos densos. Apesar da forma visual da curva, a métrica AUC permanece válida e reflete corretamente a capacidade de separação entre imagens reais e manipuladas.

5 Análise Qualitativa e Discussão

Para além da avaliação quantitativa, foi realizada uma análise qualitativa dos mapas de erro cromático, permi-




Figura 2: Mapas de erro cromático em imagens manipuladas por *inpainting*. Observa-se erro intenso e distribuído por múltiplas regiões faciais.

tindo compreender melhor o tipo de sinal aprendido pelo sistema e justificar as decisões metodológicas tomadas.

5.1 Análise Visual dos Heatmaps

As Figuras 2 e 3 ilustram exemplos representativos de mapas de erro cromático obtidos para imagens falsas e reais, respetivamente.

Nas imagens manipuladas, observa-se que:

- O erro cromático tende a ser mais intenso e irregular.
- As ativações distribuem-se por várias regiões da face (boca, nariz, olhos e contornos).
- O padrão não corresponde a uma única zona semanticamente isolada.

Em contraste, nas imagens reais:

- Os mapas apresentam ativações suaves ou residuais.
- O erro surge frequentemente fora da face (cabelo ou fundo).
- Não se observam picos sistemáticos de erro facial.

De forma geral, observa-se que os mapas associados a imagens falsas apresentam maior variância espacial e padrões menos suaves, enquanto nos casos reais o erro é mais homogêneo e de baixa intensidade.

Estes resultados confirmam que o método não atua como um segmentador de edições, mas sim como um detetor de incoerência cromática global.

5.2 Erro Cromático Fora da Região Facial

Uma observação relevante é a presença de erro cromático significativo fora da região estritamente facial em imagens falsas. Este fenómeno explica o fraco desempenho observado quando se utilizaram máscaras faciais.

A exclusão destas regiões remove informação contextual importante, sugerindo que manipulações por *inpainting* afetam não apenas a face, mas também a sua integração cromática com o contexto envolvente.

Este resultado reforça a escolha de utilizar estatísticas globais dos mapas de erro, em vez de análises locais restritas.



Figura 3: Mapas de erro cromático em imagens reais e falsas, evidenciando a presença de sinal discriminativo fora da região facial.

5.3 Discussão dos Resultados Quantitativos

O valor final de AUC obtido (aproximadamente 0.7627) demonstra uma separação consistente entre imagens reais e manipuladas, considerando a dificuldade do cenário avaliado.

Importa salientar que:

- O sistema não foi treinado explicitamente para detectar falsos.
- O modelo de *colorization* aprendeu apenas padrões de coerência cromática natural.

Assim, a capacidade de detecção resulta exclusivamente da violação dessa coerência, o que confere robustez conceptual face à evolução de técnicas de geração.

6 Conclusões e Trabalho Futuro

Neste trabalho foi proposto um método alternativo para detecção de deepfakes, baseado na análise de inconsistências cromáticas resultantes da reconstrução de cor por um modelo treinado exclusivamente com imagens reais. Todo o pipeline foi implementado de forma determinística, com divisões fixas de dados e scripts reproduzíveis, garantindo consistência experimental.

Os principais contributos do trabalho são:

- Um pipeline completo e reproduzível para detecção de manipulações por *inpainting*.
- Demonstração experimental de que incoerências cromáticas globais são um sinal discriminativo eficaz.
- Análise crítica de escolhas metodológicas, incluindo testes falhados e respetiva justificação.

Como trabalho futuro, destacam-se:

- Avaliação do método em outros tipos de manipulação facial.
- Extensão da abordagem a vídeos, explorando coerência temporal.
- Combinação com métodos complementares baseados em textura ou frequência.

Em síntese, os resultados obtidos validam a hipótese inicial do projeto e demonstram que modelos de *colorization* podem ser utilizados como ferramentas eficazes para detecção indireta de deepfakes modernos.